# EL-HAMDAOUI MAROUANE

February 17, 2026

# 1 TD-TP N° 2 Machine Learning & Text Mining

## 1.1 Techniques de régression

**Année Universitaire: 2022-2023**

## 1.2 Exercice 1: Régression linéaire simple

**Travail à faire:** 1. Analyser le programme ci-dessous en identifiant (datasets, input, output, technique utilisée…) 2. Identifier les étapes nécessaires à une application de Machine Learning (training data, testing data, testing…) 3. Quelle est le rôle de iloc ? 4. Exécuter et tester le programme 5. Afficher les valeurs de Slope, intercept, coefficient de corrélation ? 6. Prédire une estimation pour x=22.5

[ ]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
```

[22]:
```
df = pd.read_csv('univariate_linear_regression_dataset.csv')
```

[23]:
```
X = df.iloc[:,0]
Y = df.iloc[:,1]

axes = plt.axes()
axes.grid()
plt.scatter(X,Y)
plt.show()
```

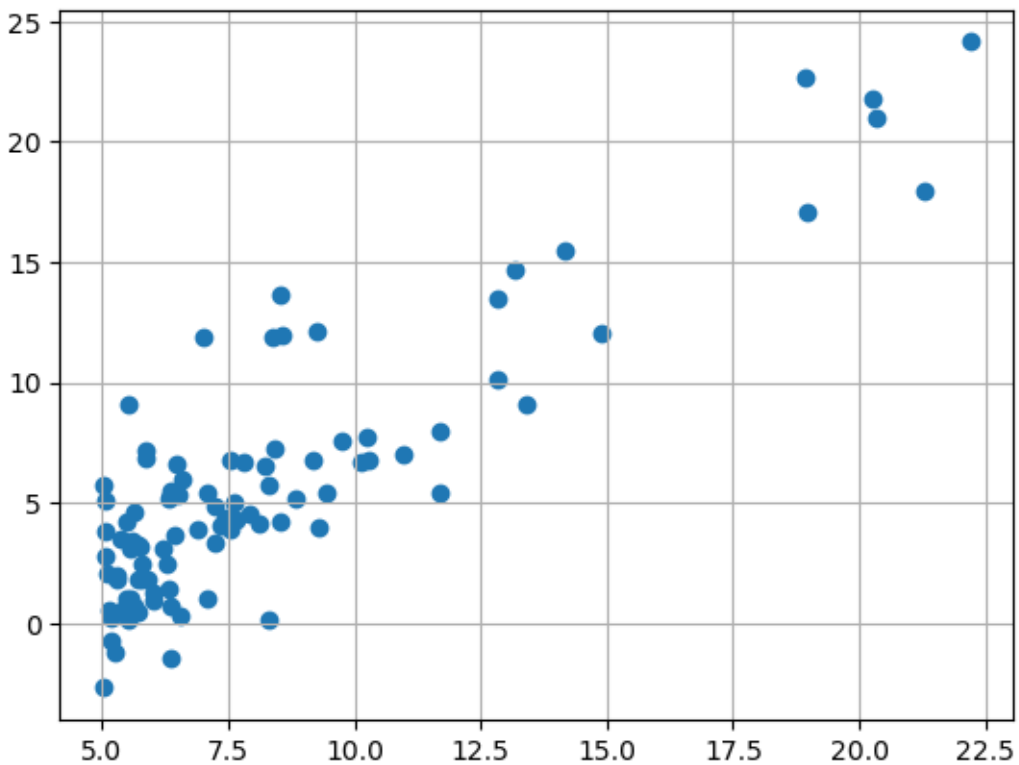


[24]:
```
SL=stats.linregress(X, Y)
slope=SL.slope; intercept=SL.intercept; coef_correlation=SL.rvalue

def predict(x):
    return slope * x + intercept

axes = plt.axes()
axes.grid()
plt.scatter(X,Y)
fitLine = predict(X)
plt.plot(X, fitLine, c='r')
plt.show()
```

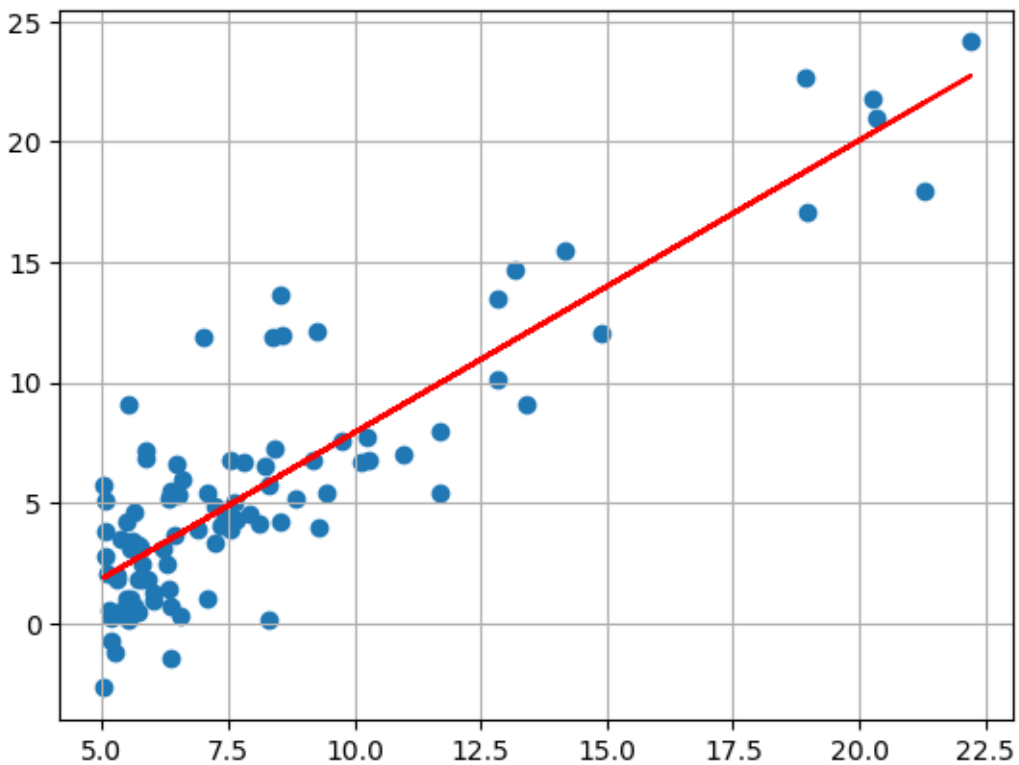


### 1.2.1 Réponses:

**Question 1:** Analyse du programme - **Réponse:** - **Dataset:** `univariate_linear_regression_dataset.csv` - un fichier CSV contenant des données pour la régression linéaire à une variable - **Input:** Variable X (première colonne du dataset) - variable prédictive/indépendante - **Output:** Variable Y (deuxième colonne du dataset) - variable cible/dépendante - **Technique utilisée:** Régression linéaire simple avec `stats.linregress()` de scipy

**Question 2:** Étapes de Machine Learning - Réponse:

**Question 3:** Rôle de iloc - Réponse:

**Question 5:** Afficher les valeurs de Slope, intercept, coefficient de corrélation

[12]:
```
# Votre code ici pour afficher slope, intercept, coef_correlation
print(f"Slope: {slope}")
print(f"Intercept: {intercept}")
print(f"Coefficient of Correlation: {coef_correlation}")
```

```
Slope: 1.1930336441895941
Intercept: -3.8957808783118555
Coefficient of Correlation: 0.837873232526341
```

**Question 6:** Prédire une estimation pour x=22.5

[14]:
```
# Votre code ici pour prédire pour x=22.5

prediction = predict(22.5)

print(f"Prediction for x=22.5: {prediction}")
```

```
Prediction for x=22.5: 22.94747611595401
```

### 1.3 Exercice 2: Régression avec Gradient Descent

**Travail à faire:** 1. Analyser le programme ci-dessous en identifiant (datasets, input, output, technique utilisée…) 2. Exécuter et tester le programme 3. Quel est le rôle de n_iterations et learning_rate ? modifier la valeur et identifier l'impact sur le modèle ?

[20]:
```
df = pd.read_csv('univariate_linear_regression_dataset.csv')
```

[28]:
```
X = df.iloc[:,0]
n_samples = len(X)
x=np.array(X).reshape((n_samples, 1))

Y = df.iloc[:,1]
y=np.array(Y).reshape((n_samples, 1))

plt.scatter(x, y)
plt.show()
```

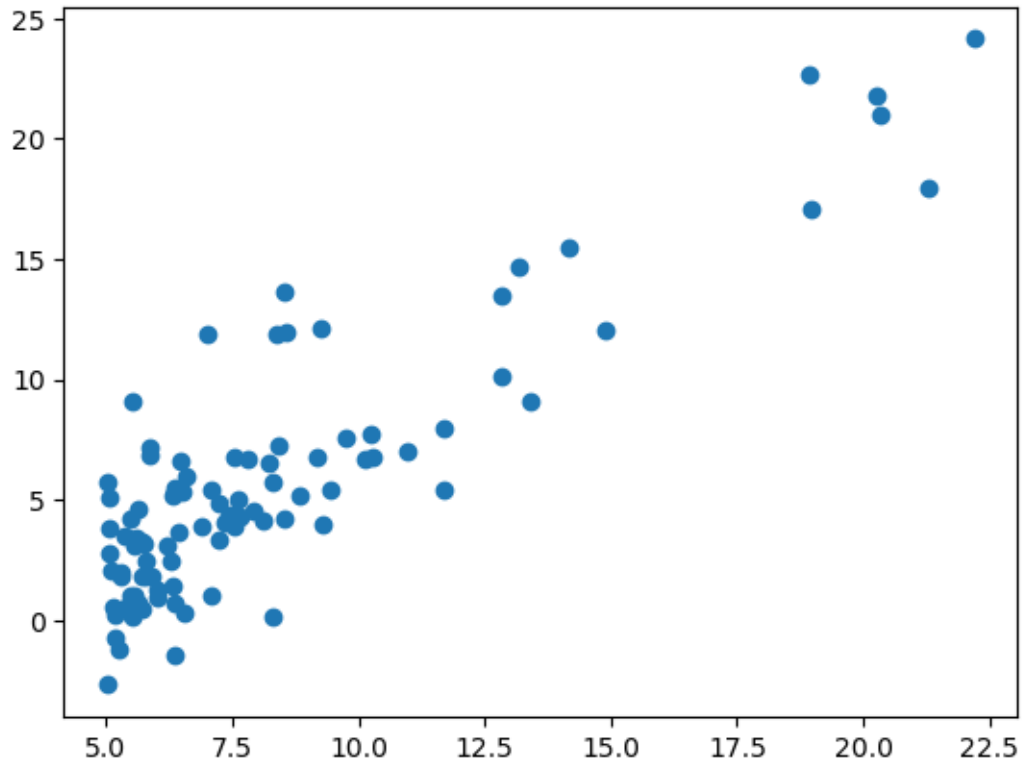

[29]:
```
# ajout de la colonne de biais x-X
X = np.hstack((x, np.ones(x.shape)))
# Initiation d'un vecteur parametre theta
theta = np.random.rand(2, 1)
print(theta)
```

```
[[0.8266758 ]
 [0.29588578]]
```

[32]:
```
def f(X, theta):
    return X.dot(theta)

def erreur_somme_des_distances(X, y, theta):
    m = len(y)
    return (1/(2*m))*np.sum((f(X, theta)-y)**2)

def gradient(X, y, theta):
    m = len(y)
    return (1/m) * X.T.dot(f(X, theta) - y)

def gradient_descent(X, y, theta, learning_rate, n_iterations):
    # création d'un tableau de stockage pour enregistrer l'évolution des erreurs
    historique_des_erreurs = np.zeros(n_iterations)
    for i in range(0, n_iterations):
        theta = theta - learning_rate * gradient(X, y, theta) # mise à jour du␣
 ↪theta
        historique_des_erreurs[i] = erreur_somme_des_distances(X, y, theta)
    return theta, historique_des_erreurs

# Example de test :
n_iterations = 10000
learning_rate = 0.01
# modifier pour voir l'effet
theta_final, historique_des_erreurs=gradient_descent(X, y, theta,␣
 ↪learning_rate, n_iterations)

# creation d'un vecteur prédictions qui contient les prédictions de notre␣
 ↪modèle final
predictions = f(X, theta_final)

# Affiche les résultats de prédictions (en rouge) par rapport à notre Dataset␣
 ↪(en bleu)
plt.scatter(x, y)
plt.plot(x, predictions, c='r')
plt.show()
```

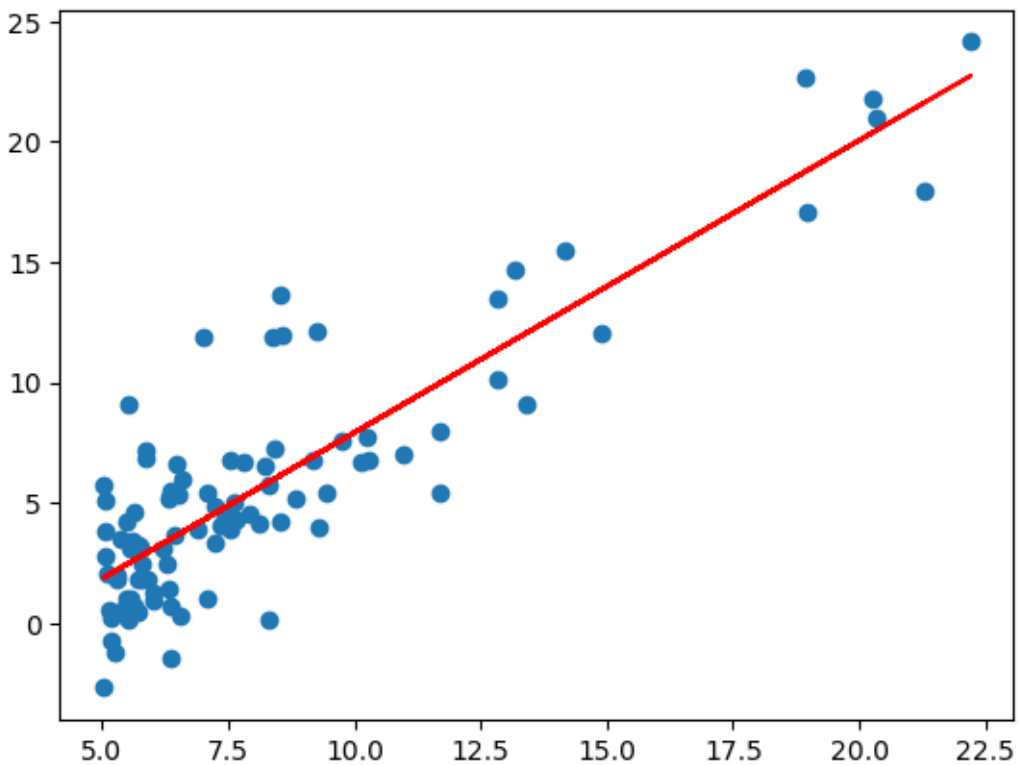


[31]:
```
plt.figure()
plt.plot(range(n_iterations), historique_des_erreurs)
plt.show()

print(f'np.array([22.5,1]), theta_final)')
```

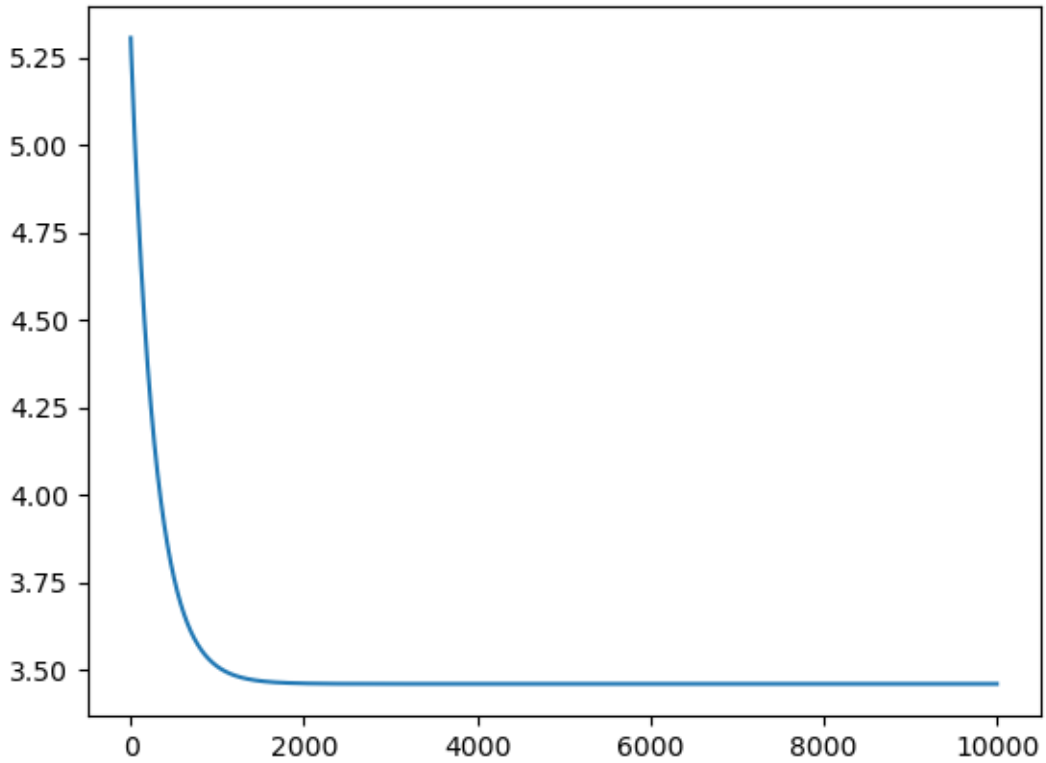


```
np.array([22.5,1]), theta_final)
```

### 1.3.1 Réponses:

**Question 1:** Analyse du programme - **Réponse:** - **Dataset:** `univariate_linear_regression_dataset.csv` - un fichier CSV contenant des données pour la régression linéaire à une variable - **Input:** Variable X (première colonne du dataset) - variable prédictive/indépendante
- **Output:** Variable Y (deuxième colonne du dataset) - variable cible/dépendante - **Technique utilisée:** Régression linéaire avec descente de gradient (Gradient Descent) - une méthode d'optimisation itérative pour trouver les paramètres optimaux (theta) du modèle linéaire

**Question 3:** Rôle de n_iterations et learning_rate - **Réponse:** - **n_iterations:** Nombre d'itérations de l'algorithme de descente de gradient. Plus ce nombre est élevé, plus l'algorithme a de chances de converger vers les paramètres optimaux. - **learning_rate:** Taux d'apprentissage qui contrôle la taille des pas lors de la mise à jour des paramètres theta. - Si trop petit: la convergence sera très lente et nécessitera beaucoup d'itérations - Si trop grand: l'algorithme peut diverger ou osciller sans jamais converger vers l'optimum - Une valeur appropriée permet une convergence rapide et stable vers les paramètres optimaux

## 1.4 Exercice 3: Régression polynomiale

**Travail à faire:** 1. Analyser le programme ci-dessous en identifiant (dataset, input, output, technique utilisée…) 2. Quel est le rôle des fonctions afficher_pol et evaluer_pol ? 3. Exécuter et

tester le programme 4. Est-ce que le polynôme modélise correctement la relation entre la variable prédictive et la variable cible ? sinon chercher une polynôme adéquate ?

[39]:
```
def afficher_pol(LPol):
    L=LPol[:]; L.reverse()
    L=[round(e,2) for e in L]

    for i in range(len(L)):
        if i != len(L)-1:
            print('('+str(L[i])+'*X^'+str(i)+')',end=' + ')
        else:
            print('('+str(L[i])+'*X^'+str(i)+')')

def Evaluer_pol(LPol,x):
    s=0
    L=LPol[:]
    L.reverse()
    for i in range(len(LPol)):
        s+=L[i]*(x**i)
    return(s)

data=pandas.read_csv('dataset_polynomial3.csv').values

print(data)

x=data[1:1001,0]
y=data[1:1001,1]
```

```
[[ 2.69151718 -0.48494203]
 [ 1.33394826  0.39681172]
 [ 0.71045428 -0.8569272 ]
 …
 [ 0.13748415 -6.83358907]
 [ 0.75902601 -0.70444958]
 [ 3.99489162  6.33265488]]
```

### 1.4.1 Réponses:

**Question 1:** Analyse du programme - **Réponse:** - **Dataset:** `dataset_polynomial3.csv` - un fichier CSV contenant des données pour la régression polynomiale - **Input:** Variable x (première colonne du dataset) - variable prédictive/indépendante - **Output:** Variable y (deuxième colonne du dataset) - variable cible/dépendante - **Technique utilisée:** Régression polynomiale avec `np.polyfit()` qui ajuste un polynôme de degré spécifié aux données

**Question 2:** Rôle des fonctions afficher_pol et evaluer_pol - **Réponse:** - **afficher_pol(LPol):** Affiche le polynôme sous forme mathématique lisible en inversant l'ordre des coefficients et en les formatant comme une somme de termes (coefficient * X^puissance) - **Evaluer_pol(LPol, x):** Évalue le polynôme pour une valeur x donnée en calculant la somme des termes (coefficient * x^puissance) pour tous les coefficients du polynôme

**Question 4:** Le polynôme modélise-t-il correctement la relation ? - **Réponse:** - Non, un polynôme de degré 2 ne modélise pas correctement la relation entre les variables. En observant les données, on constate qu'il s'agit d'un dataset polynomial de degré 3 (d'après le nom du fichier). Il faudrait augmenter le degré du polynôme à 3 pour obtenir un meilleur ajustement. On peut tester différents degrés (3, 4, 5…) pour identifier le degré optimal qui modélise correctement les données sans sur-apprentissage.

[ ]:
```
for degre_polynome in range(1, 5):
    p = np.poly1d(np.polyfit(x, y, degre_polynome))
    LPol = list(p)

    print(f"Degré du polynôme: {degre_polynome}")

    afficher_pol(LPol)

    les_x = np.linspace(min(x), max(x), 100)
    plt.scatter(x, y)
    plt.plot(les_x, p(les_x), c='r')
    plt.title(f"Fit polynomial of degree {degre_polynome}")
    plt.show()
```

```
Degré du polynôme: 1
(-3.34*X^0) + (1.68*X^1)
```

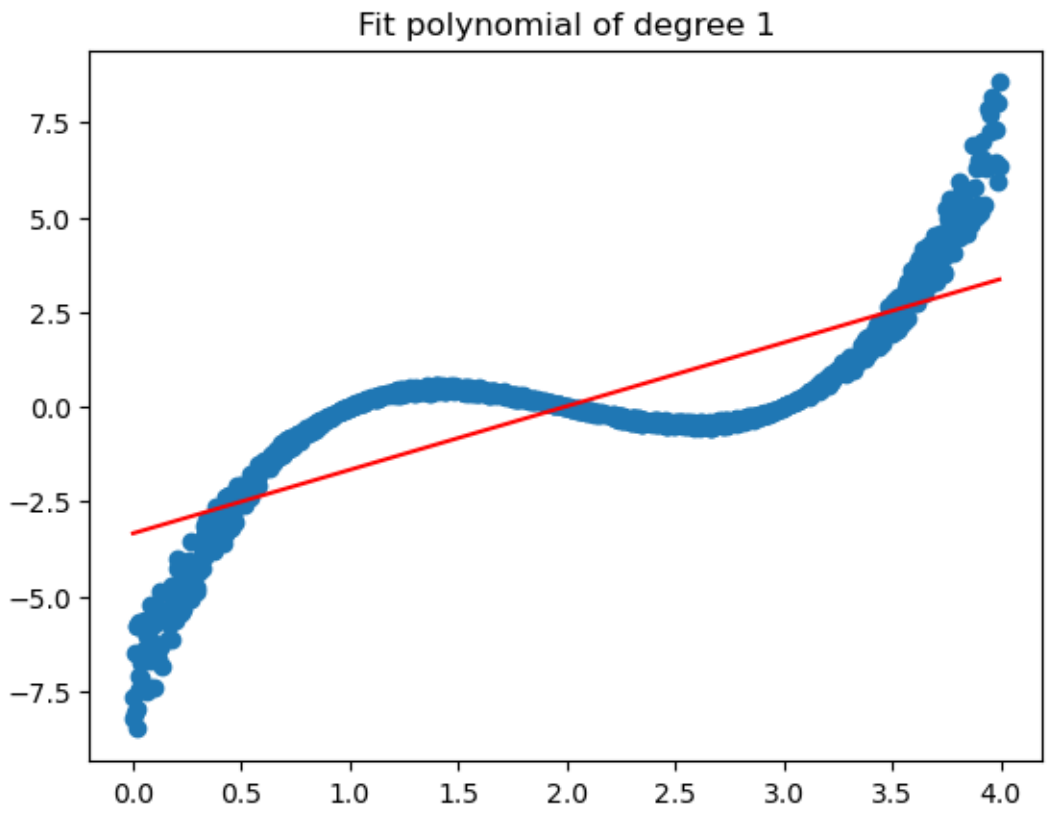

```
Degré du polynôme: 2
(-3.45*X^0) + (1.84*X^1) + (-0.04*X^2)
```

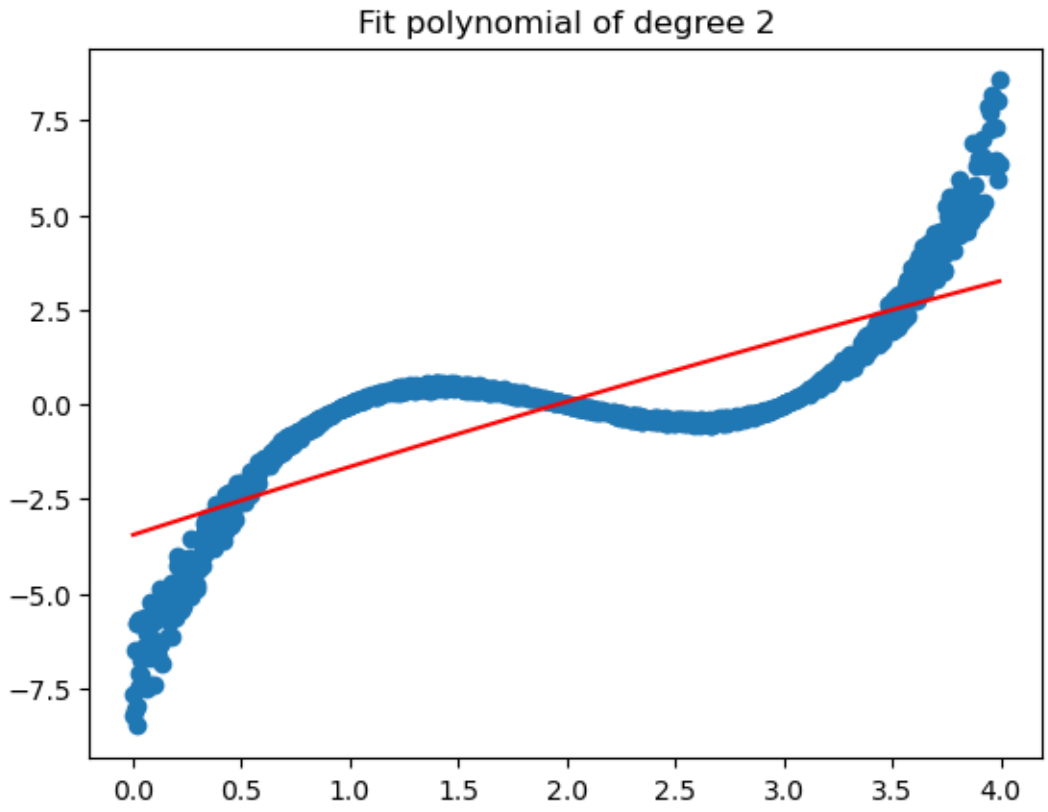


```
Degré du polynôme: 3
(-7.38*X^0) + (13.53*X^1) + (-7.38*X^2) + (1.23*X^3)
```

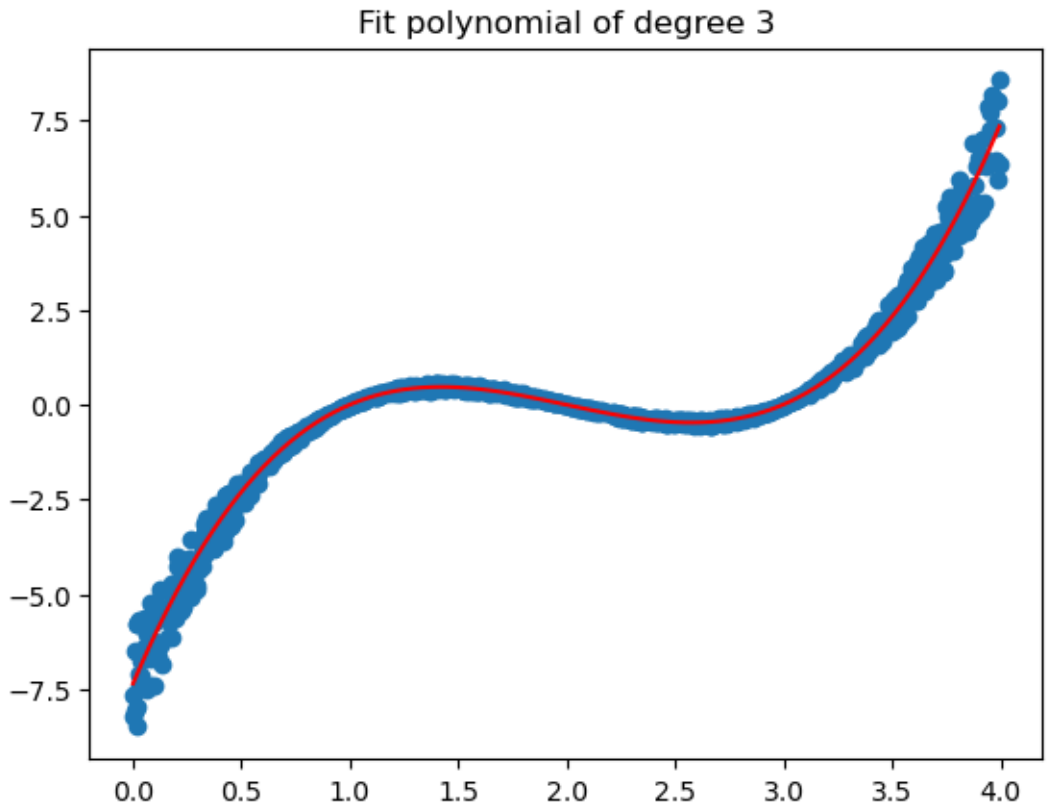


```
Degré du polynôme: 4
(-7.4*X^0) + (13.6*X^1) + (-7.47*X^2) + (1.26*X^3) + (-0.0*X^4)
```

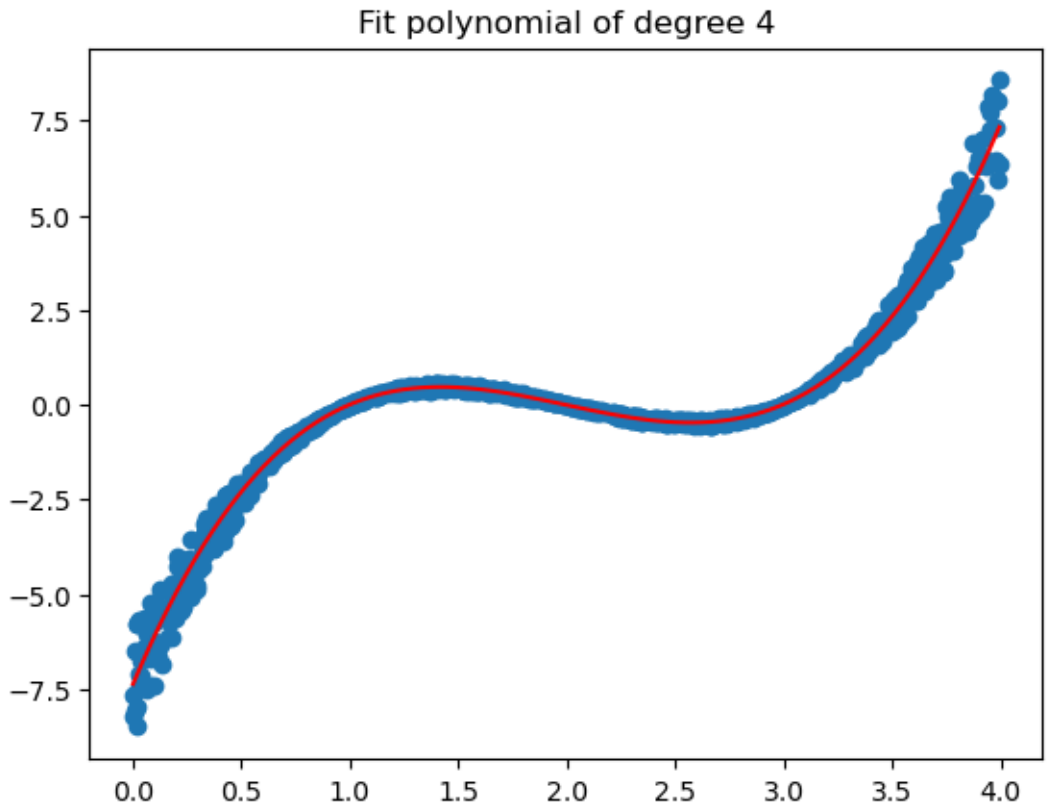
Fit polynomial of degree 4
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
4.0