Machine Learning & Text Mining

Année universitaire : 2022-2023

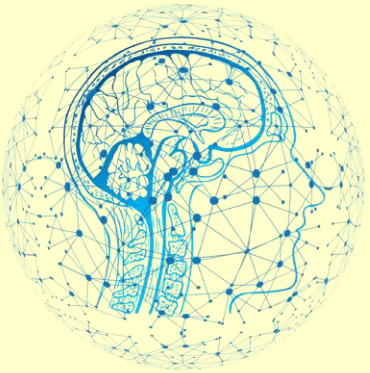

Pr. Abdelali ZAKRANI

Professeur Habilité à ENSAM de Casablanca

Docteur en informatique de l'ENSIAS

Introduction à l'apprentissage automatique

Définition: Machine Learning (apprentissage automatique) concerne l'étude, la conception et le développement d'algorithmes qui permettent aux ordinateurs d'apprendre sans être explicitement programmés (Arthur Samuel).

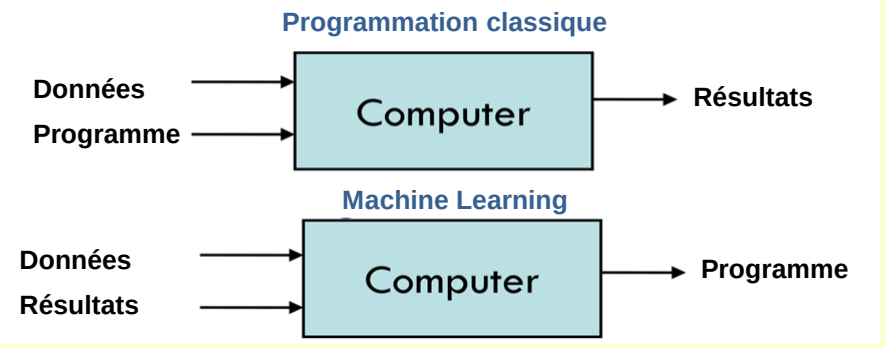

Introduction à l'apprentissage automatique

Programmation classique:

- Développement de programmes pour la gestion de stock
- Administration d'une entreprise, ….
- Gestion d'un cabinet de formations, …..

On peut trouver un algorithme qui permet de trouver les résultats à partir des données saisies par l'utilisateur.

Exemple:

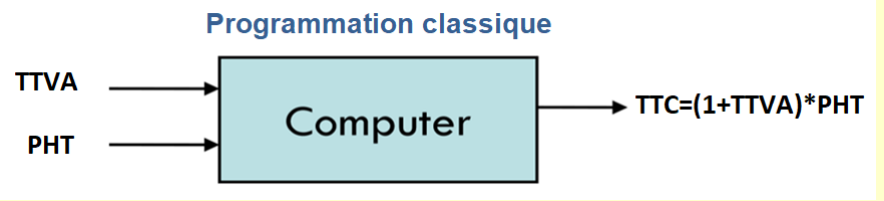

3

Introduction à l'apprentissage automatique

Machine Learning: On ne dispose pas d'une formule ou d'une méthode analytique qui permet de trouver les résultats à partir des données.

Connaissez vous une méthode analytique qui permet de reconnaitre l'une des images suivantes ? S'agit-il du chiffre 6 ou 9 ou la lettre v ?

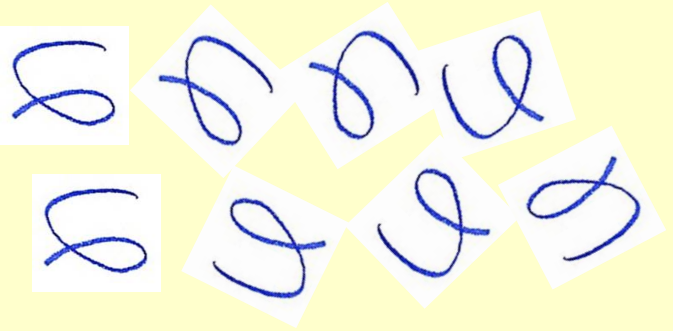

4

Quelques applications de Machine Learning

Exemples:

- **Prédiction des prix:** Estimer le prix d'une maison en fonction de sa superficie, sa localisation, possibilité de Parking ou non etc… Ces estimations sont faites en observant d'autres produits similaires pour en tirer des conclusions.

- **Diagnostique médical:** En se basant sur les données médicales d'un patient, l'algorithme peut diagnostiquer si le sujet est atteint d'une maladie donnée. Parfois, ces algorithmes peuvent alerter d'un incident grave de santé avant que cela n'arrive, notamment pour les crises cardiaques.

5

Quelques applications de Machine Learning

https://www.01net.com/actualites/ia-ces-chercheurs-ont-decouvert-un-puissant-antibiotique-grace-a-l-apprentissage-automatique-1862232.html?fbclid=IwAR0sdwCFrxJdMg2d75jAtGZ1EF_JH21ouRfr98v2hx2cEHpzYcH0R9QSTvM

Le 21 avril 2020, Des chercheurs du MIT (Massachussetts Institute of Technology) ont créé un algorithme capable de trouver automatiquement de nouveaux antibiotiques, ce qui devrait ravir l'industrie pharmaceutique en s'appuyant sur des techniques d'apprentissage automatique.
Cette découverte est d'autant plus importante que les bactéries ont tendance à devenir de plus en résistantes. Cette nouvelle méthode fondée sur l'intelligence artificielle pourrait donc sauver les vies des millions de personnes.

6

Quelques applications de Machine Learning

- **Recommandation de produits:** Ce type de système se base sur les historiques d'achats, les recherches faites en ligne (Tracking Web) par un internaute pour lui recommander des produits qui pourront l'intéresser. Pour Amazon, cette fonctionnalité est critique car elle est au cœur de l'augmentation des volumes de vente et par conséquent des gains de la société.
- **Regroupement d'items:** Ce type de technique sert notamment pour l'application Iphoto d'Apple pour regrouper les images en fonction des gens qui s'y retrouvent. Généralement, les données n'ont pas d'étiquettes, et l'algorithme tentera de retrouver des items similaires et les regroupera dans un même groupe.

7

Quelques applications de Machine Learning

- **Conduite autonome:** En apprenant le comportement de conduite des humains, les algorithmes de Deep Learning avec l'apprentissage par renforcement (reinforcement learning) permettent d'apprendre des tâches complexes comme la conduite.
- **Banque et Assurance:**

  Prédire qu'un client va quitter sa banque.
  Définir ceux qui veulent changer leur assurance vie.
  Améliorer la satisfaction client en proposant les offres les plus pertinentes possibles.

  Prise de décision pour donner un crédit à un client ou non, prédire les risques, ….

8

Quelques applications de Machine Learning

Une banque reçoit quotidiennement plusieurs demandes d'approbation de crédit. Elle veut automatiser leurs processus d'évaluation. La banque n'a pas de formule magique pour savoir quand il faut accorder un crédit, mais il a beaucoup de données.

L'existence de données nous ramène à l'approche d'apprentissage des données. Donc, la banque utilise l'historique des documents des anciens clients pour trouver la bonne formule d'approbation de crédit.

Application du Machine Learning

1- Existence d'un modèle à apprendre: Il existe une corrélation entre les variables d'entrées et de sorties. On sait qu'un modèle existe même si on le connait pas.

2-Modélisation mathématique est impossible: On ne peut pas résoudre le modèle mathématiquement (pas de solution analytique).

3- Existence des données: Il existe des données qui représentent le modèle.

Datasets: exemples
https://archive.ics.uci.edu/ml/index.php
https://www.kaggle.com/datasets

L'apprentissage automatique est une branche de l'intelligence artificielle

Le **Machine Learning** ou **Apprentissage automatique** est une branche de l'intelligence artificielle qui concerne la conception, l'analyse, le développement et l'implémentation de modèles, permettant à une machine d'apprendre à partir des données par un processus systématique afin de remplir une tâche.

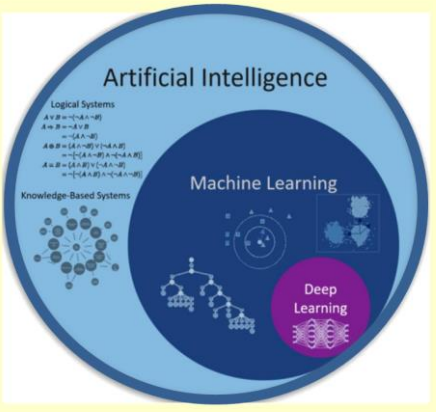

11

Les types d'apprentissage automatique

- Apprentissage supervisé (supervised learning)
- Non supervisé (unsupervised learning)
- Semi supervisé (semi-supervised learning)
- Par renforcement(reinforcement learning)

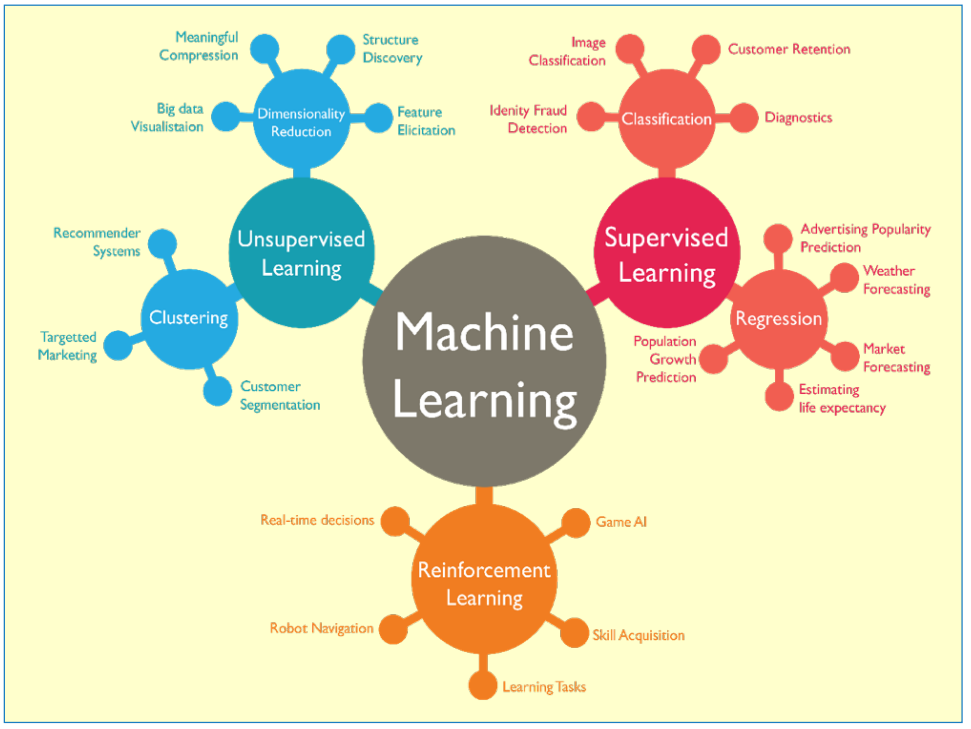

Apprentissage supervisé (supervised learning)

Des données (entrées) annotées de leurs sorties pour entraîner le modèle, c'est-à-dire que à chaque **entrée est** associée à une classe **cible (sortie)**, une fois entraîné, le modèle (l'algorithme de ML) devient capable de prédire (éventuellement avec un pourcentage d'erreur) la cible sur de **nouvelles données** non annotées.

Exemple:

Les données d'entrée représentent des images et la cible (ou *target* en anglais) représente la catégorie de photos.

Apprentissage supervisé (supervised learning)

Voiture

Oiseau

Chat

Chien

cheval

15

Apprentissage supervisé (supervised learning)

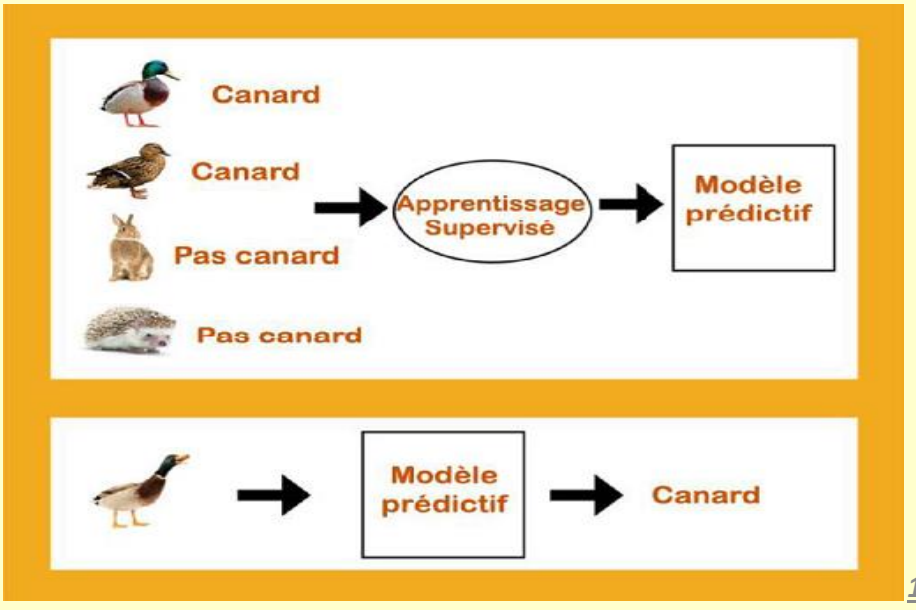

16

Apprentissage supervisé (supervised learning)

Techniques supervisées (prédictive)

- **Classification**
- **Régression Estimation**

- **Arbre de décision**
- **Réseaux de neurone**
- **Naïve Bayes**
- **Machines à vecteurs supports (SVM)**
- **K-Nearest Neighbour (K-NN)**

17

Apprentissage non supervisé (unsupervised learning)

En apprentissage non supervisé, les données d'entrées ne sont pas annotées. L'algorithme d'entraînement s'applique dans ce cas à trouver les similarités et distinctions au sein de ces données, et à regrouper ensemble celles qui partagent des caractéristiques communes. Dans notre exemple, les photos similaires seraient ainsi regroupées automatiquement au sein d'une même catégorie.

18

Apprentissage non supervisé (unsupervised learning)

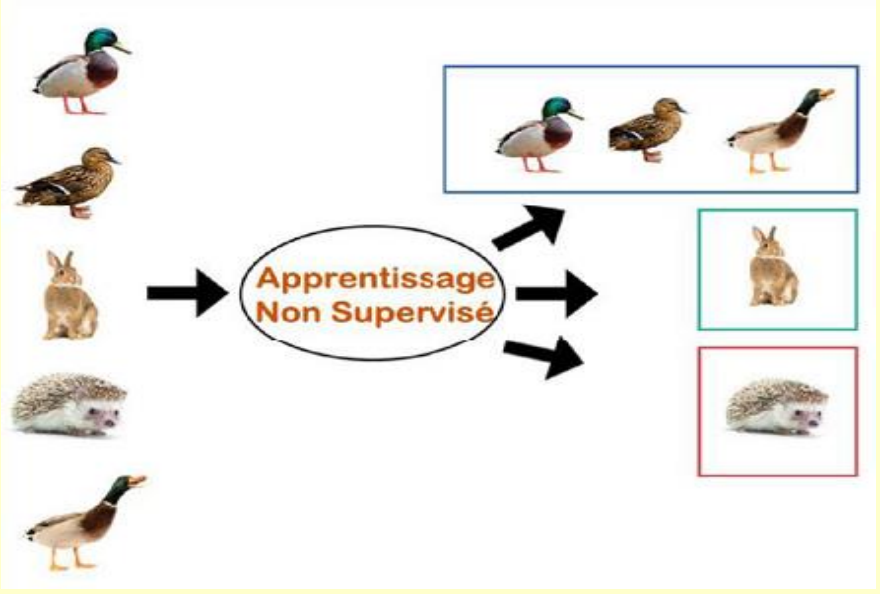

19

Apprentissage non supervisé (unsupervised learning)

Techniques non supervisées (descriptive)

Clustering	Associations
K-Means K-moyennes	Apriori Eclat, FP-growth RElim, SaM, JIM
Expectation Maximisation (EM)	

20

Apprentissage sem-supervisé (semi-supervised learning)

- L'**apprentissage semi-supervisé** est une classe de techniques d'apprentissage automatique qui utilise un ensemble de données étiquetées et non étiquetées. Il se situe ainsi entre l'apprentissage supervisé qui n'utilise que des données étiquetées et l'apprentissage non supervisé qui n'utilise que des données non étiquetées. Il a été démontré que l'utilisation de données non étiquetées, en combinaison avec des données étiquetées, permet d'améliorer significativement la qualité de l'apprentissage.
- Un autre intérêt provient du fait que l'étiquetage de données nécessite souvent l'intervention d'un utilisateur humain. Lorsque les jeux de données deviennent très grands, cette opération peut s'avérer fastidieuse. Dans ce cas, l'apprentissage semi-supervisé, qui ne nécessite que quelques étiquettes, revêt un intérêt pratique évident.

Apprentissage par renforcement(reinforcement learning)

L'**apprentissage par renforcement** consiste, pour un agent autonome (robot, etc.), à apprendre les actions à prendre, à partir d'expériences, de façon à optimiser une récompense quantitative au cours du temps. L'agent est plongé au sein d'un environnement, et prend ses décisions en fonction de son état courant. En retour, l'environnement procure à l'agent une récompense, qui peut être positive ou négative. L'agent cherche, au travers d'expériences itérées, un comportement décisionnel (appelé *stratégie* ou *politique*, et qui est une fonction associant à l'état courant l'action à exécuter) optimal, en ce sens qu'il maximise la somme des récompenses au cours du temps.

Les 7 étapes de l'apprentissage automatique

L'apprentissage automatique ne se résume pas à un ensemble d'algorithmes mais suit une succession d'étapes:

1) **L'acquisition de données :** l'algorithme se nourrissant des données en entrée, c'est une étape importante. Il en va de la réussite du projet, de récolter des données pertinentes et en quantité suffisante.

2) **La préparation et le nettoyage de la donnée :** les données recueillies doivent être retouchées avant utilisation. En effet, certains attributs sont inutiles, d'autre doivent être modifiés afin d'être compris par l'algorithme, et certains éléments sont inutilisables car leurs données sont incomplètes.

23

Les 7 étapes de l'apprentissage automatique

3) **Choix du modèle.**

4) **Formation et apprentissage du modèle**

5) **L'évaluation :** une fois l'algorithme d'apprentissage automatique entraîné sur un premier jeu de donnée, on l'évalue sur un deuxième ensemble de données afin de vérifier que le modèle ne fasse pas de surapprentissage.

6) **Réglage des paramètres:** Ajuster les paramètres pour de meilleures performances

7) **Le déploiement :** le modèle est déployé en production pour faire des prédictions, et potentiellement utiliser les nouvelles données en entrée pour se ré-entraîner et être amélioré.

24

Classification binaire

- La classification est une tâche très répandue en Machine Learning. Dans ce genre de problématique, on cherche à mettre une étiquette (un label) sur une observation : une tumeur est-elle maligne ou non, une transaction est- elle frauduleuse ou non… ces deux cas sont des exemples de classification.
- Quand on a deux choix d'étiquettes possibles (tumeur maligne ou non), on parle de Binary Classification (classification binaire). Par ailleurs, l'étiquette Y aura deux valeurs possibles 0 ou 1. En d'autres termes $Y \in \{0,1\}$

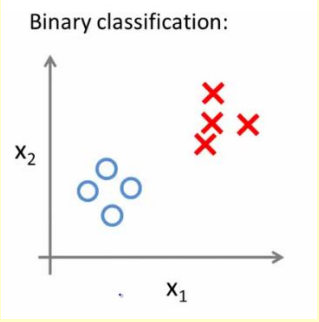

25

Classification binaire et multiclasses

Le but du jeu c'est qu'on trouve une ligne (Boundary Decision) séparant les deux groupes (les cercles et les carrés).

Note : Pour l'exemple de la tumeur, on peut attribuer arbitrairement la classe (étiquette) 1 pour dire qu'il s'agit d'une tumeur maligne et la valeur 0 pour les tumeurs bénignes.

Quand notre problème a plusieurs étiquettes possibles (par exemple classifier un article dans une catégorie ("sport", "politique", "High-Tech")…), on parle de Multi-class classification. Dans ce cas on peut attribuer arbitrairement les numéros des classes aux observations du Training Set. Dans l'exemple vu en TP en haut pour la reconnaissance des chiffres : dix classes: 0,1,2,3,4,5,6,7,8,9

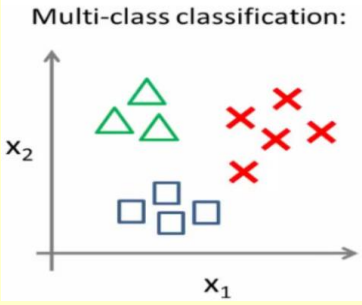

26

Application de Machine Learning sur la reconnaissance des nombres manuscrits

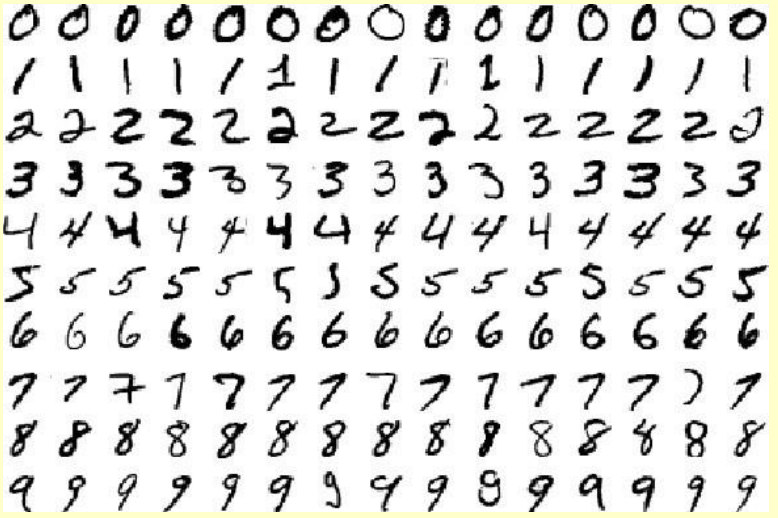

27

Application de Machine Learning sur la reconnaissance des nombres manuscrits

Prenons des images en niveau de gris : chaque pixel est codé sur 8 bits
Pixel est représenté par un nombre compris entre 0 et 255.
Valeur du pixel proche de 0: noir
Valeur du pixel proche de 1: blanc

28

Application de Machine Learning sur la reconnaissance des nombres manuscrits

```
import numpy as np
import matplotlib.pyplot as plt
import pandas
from sklearn.tree import DecisionTreeClassifier
data=pandas.read_csv("d:\\train.csv").as_matrix()
clf=DecisionTreeClassifier()
x=data[0:21000,1:]
label=data[0:21000,0]
clf.fit(x,label)
xtest=data[21000:,1:]
actual_label=data[21000:,0]
p=clf.predict(xtest)
```

29

Application de Machine Learning sur la reconnaissance des nombres manuscrits

```
p=clf.predict(xtest)
count=0
for i in range(0,21000):
count+=1 if p[i]==actual_label[i] else 0
print("Accuracy=",(count/21000)*100)
d=xtest[5]
Nombre_de_pixels_errones=100
for i in range(Nombre_de_pixels_errones):
    position=np.random.randint(0,784,1)[0]
    bruit=np.random.randint(-200,200,1)[0]
    d[position]+=bruit
    d[position]=d[position]%255
print(clf.predict([d]))
d.shape=(28,28)
plt.imshow(255-d,cmap='gray')
plt.show()
```

30

Application de Machine Learning sur la reconnaissance des nombres manuscrits

Avec un Nombre_de_pixels_errones=100 on obtient l'image suivante:

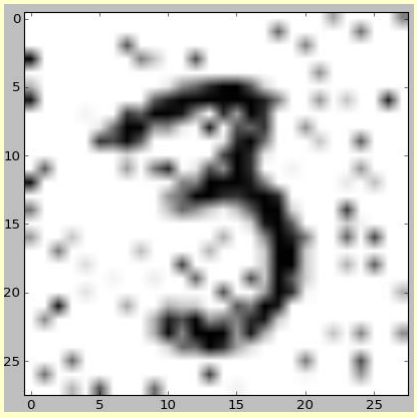

L'instruction print(clf.predict([d])) a donné la valeur 3 donc une reconnaissance réussie

31

Application de Machine Learning sur la reconnaissance des nombres manuscrits

Avec un Nombre_de_pixels_errones=500 on obtient l'image suivante:

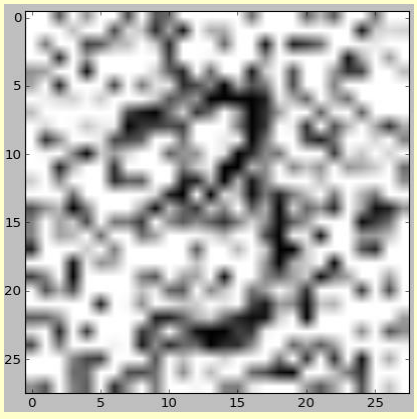

L'instruction print(clf.predict([d])) a donné la valeur 5 donc une reconnaissance non réussie à cause du bruit très fort.

32

Application de Machine Learning sur la reconnaissance des nombres manuscrits

Le programme donné en haut a pu reconnaitre l'image suivante: chiffre 2

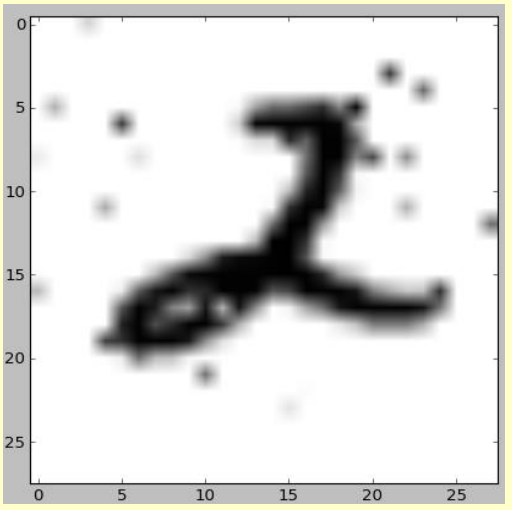

33