ÉCOLE NATIONALE SUPÉRIEURE D'ARTS ET MÉTIERS
UNIVERSITÉ HASSAN II DE CASABLANCA

Année Universitaire : 2022-2023

TD N° 6 Machine Learning & Text Mining
Les arbres de décision

Considérons le programme suivant pour le calcul de l'entropie

```
from numpy import *
import pandas
df = pandas.DataFrame([[0,1,'C1'],[0,0,'C1'],
[1,1,'C2'],[1,0,'C2']],columns=['A', 'B', 'Classes'])
df=df.to_numpy()

def Entropie(S):
    classes_distinctes=set(S[:,-1])
    classes=list(S[:,-1])
    s=0
    for c in classes_distinctes:
        p=classes.count(c)/len(classes)
        s+=p*log2(p)
    return(-1.0*s)
print(Entropie(df))
```

Travail à faire :

1. Quel est le rôle de la méthode **to_numpy()** ?

   ……

2. Quel est le résultat de ***set(S[:,-1]) ?***

   ……

3. Quel est le résultat de list(S[:,-1]) ***?***

   …… …….

4. Exécuter le programme et noter l'entropie :

   ……

5. Changer le DataFrame df de tel sorte à avoir une entropie égale à 0 et une entropie supérieure à 1.

   ……

   ……

Considérons le programme suivant pour le calcul du gain de l'information

```
16. def Gain_d_information(S,numero_colon_attribut):
17.     classes=list(set(S[:,-1]))
18.     valeurs_attribut=list(set(S[:,numero_colon_attribut]))
19.     Si=[[] for i in range(len(valeurs_attribut))]
20.     for e in S:
21.         e=list(e)
22.         val_attribut_pour_e=e[numero_colon_attribut]
23.         numero_sous_ensemble=valeurs_attribut.index(val_attribut_pour_e)
24.         Si[numero_sous_ensemble].append(e)
25.     Si=array(Si) ;  som=0
26.     for sous_ensemble in Si:
27.         som+=(len(sous_ensemble)/len(S))*Entropie(sous_ensemble)
28.     return(Entropie(S)-som)
```

Travail à faire :

6. Analyser et exécuter le programme en identifiant l'objectif des lignes :

```
valeurs_attribut=list(set(S[:,numero_colon_attribut]))
```

……

……

```
for e in S:  (cette boucle de ligne 20 à 24)
```

……

…… ……

7. Calculer le gain de l'information des différents attributs :

……

……

……

8. Calculer les gains d'information concernant cette dataset :

	A	B	C
1	Douleur	Inanime	Infarctus
2	poitrine	oui	oui
3	ailleurs	oui	oui
4	poitrine	non	oui
5	poitrine	oui	oui
6	ailleurs	non	oui
7	poitrine	non	non
8	ailleurs	non	non
9	poitrine	oui	non
10	ailleurs	non	non
11	ailleurs	non	non

9. En se basant sur les fonctions précédentes :
   a. Ecrire une fonction **GINI(S)** qui calcule et retourne l'indice de GINI d'un ensemble
   b. Ecrire une fonction **Mesure_desordre(S,numero_colon_attribut)** qui calcule et retourne le désordre selon un attribut de partitionnement
   c. Utiliser le programme obtenu pour calculer Indice de GINI et le désordre des DataFrame précédents.

Considérons la fonction suivante qui calcule le désordre pour les valeurs continues :

```
22 def Mesure_desordre(S,numero_colon_attribut):
23     Bonne_mesure_desordre=+inf
24     Bonne_valeur_de_repartition=0
25     classes=list(set(S[:,-1]))
26     valeurs_attribut=list(set(S[:,numero_colon_attribut]))
27     valeurs_attribut.sort()
28     Gauche=[]; Droite=[]
29     for i in range(len(valeurs_attribut)-1):#le dernier est le max !
30         v=valeurs_attribut[i]; Gauche.clear(); Droite.clear()
31         for e in S:
32             val_attribut_pour_e=e[numero_colon_attribut]
33             if val_attribut_pour_e<=v:
34                 Gauche.append(e)
35             else:
36                 Droite.append(e)
37         pGau=len(Gauche)/len(S)
38         pDr=len(Droite)/len(S)
39         mesure=(pGau)*GINI(Gauche)+(pDr)*GINI(Droite)
40         if mesure<Bonne_mesure_desordre:
41             Bonne_mesure_desordre=mesure
42             Bonne_valeur_de_repartition=v
43     return(Bonne_mesure_desordre,Bonne_valeur_de_repartition)
```

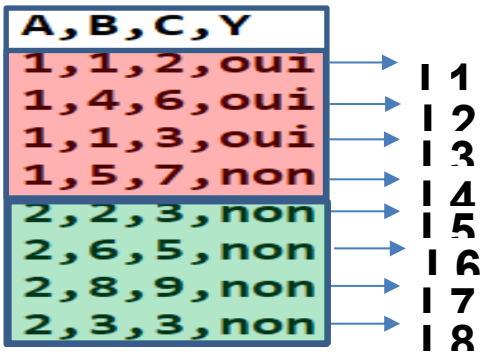

10. Expliquer comment la fonction calcule et retourne la valeur de répartition ?

……

……

……

11. Comment peut-on sélectionner le meilleur attribut à utiliser le partitionnement et la meilleure valeur ?

Considérons le programme suivant :

```
def meilleur_attribut_meilleure_valeur(S):
    meilleur_attribut=0
    meilleure_val=0
    meilleure_mesure=+inf
    for num_attribut in range(len(S[0])-1):
        mesure,valeur=Mesure_desordre(S,num_attribut)
        if mesure<meilleure_mesure:
            meilleure_val=valeur
            meilleure_mesure=mesure
            meilleur_attribut=num_attribut
    return meilleur_attribut,meilleure_val
print(meilleur_attribut_meilleure_valeur(Data_train))
```

12. Exécuter ce programme et noter les résultats concernant le meilleur attribut à utiliser le partitionnement et la meilleure valeur ?

Considérons le programme suivant :

```
X = data[:8,0:3]; Y = data[:8,3] ; X_test=data[8:,0:3];  y_test=data[8:,3]
clf_gini = DecisionTreeClassifier(criterion = "gini")
clf_gini.fit(X, Y)
clf_entropy = DecisionTreeClassifier(criterion = "entropy")
clf_entropy.fit(X, Y)
print("Results Using Gini Index:")
y_pred_gini = clf_gini.predict(X_test)
print("Confusion Matrix: ",confusion_matrix(y_test, y_pred_gini))
print(X_test,y_test,y_pred_gini)
print ("Accuracy : ",accuracy_score(y_test,y_pred_gini)*100)
print("Results Using Entropy:")
y_pred_entropy = clf_entropy.predict(X_test)
print("Confusion Matrix: ",confusion_matrix(y_test, y_pred_entropy))
print ("Accuracy : ",accuracy_score(y_test,y_pred_entropy)*100)
```

13. Combien y a-t-il de données dans l'ensemble d'apprentissage et dans l'ensemble de test ?
14. Quel est le meilleur critère à utiliser dans l'arbre de décision ? entropie ou l'indice de GINI ?
15. Avec l'indice GINI ? quel est le nombre de Fp et Fn ?

Pour visualiser l'arbre de décision générer utiliser le code suivant :

```
from sklearn.externals.six import StringIO
from IPython.display import Image
from sklearn.tree import export_graphviz
import pydotplus
```

```
dot_data = StringIO()
export_graphviz(clf_gini, out_file=dot_data,
                filled=True, rounded=True,
                special_characters=True)
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())

svg_graph = graph.create_svg()
svg = open('gini_tree.svg', 'wb')
svg.write(svg_graph)
svg.close()
Image(graph.create_png())
```